

AJUSTE DE CURVAS:  
MÉTODO DOS MÍNIMOS  
QUADRADOS, MÉTODO  
POLINOMIAL E  
LINEARIZAÇÃO

PARTE I – REGRESSÃO  
LINEAR


# Computação Científica

prof. Marco Villaça

# Regressão Linear

O objetivo da regressão linear é determinar a “melhor” reta que se ajuste a um conjunto de dados.


Exemplo: Experimento do túnel de vento para medir como a força da resistência do ar depende da velocidade



# REGRESSÃO LINEAR

$v, \text{ m/s}$	10	20	30	40	50	60	70	80
$F, \text{ N}$	25	70	380	550	610	1220	830	1450

Dados experimentais para a força e a velocidade em um experimento de túnel de vento e gráfico correspondente



# REGRESSÃO LINEAR

---

- Linear em estatística significa que a resposta deve ser uma combinação linear de variáveis explicativas.
- O problema básico é encontrar a melhor linha reta  $y = a_0 + a_1 x$ , dado que  $i \in \{1, \dots, N\}$  e os pares  $(y_i, x_i)$  são observados.
- O método é facilmente generalizado para encontrar o melhor ajuste da forma

$$y = a_1 f_1(x) + \dots + a_k f_k(x)$$

- Não é necessário que as funções  $f_k$  sejam lineares em  $x$ :
  - ✓ Tudo o que é necessário é que  $y$  seja uma combinação linear dessas funções.

# Método dos mínimos quadrados

---

- Determinar uma função aproximada que ajuste a tendência geral dos dados sem necessariamente passar pelos pontos individuais.
- O exemplo mais simples é o ajuste de uma reta a um conjunto de pares de observação  $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$

$$y = a_0 + a_1 x + e \tag{i}$$

onde:  $a_0$  – intersecção com o eixo  $y$ ;

$a_1$  – inclinação da reta

$e$  = erro ou resíduo entre o modelo e a observação

# Método dos mínimos quadrados

---

- O erro ou resíduo é, portanto, descrito por

$$e = y - (a_0 + a_1 x)$$

- O ajuste dos parâmetros pelo MMQ consiste em determinar os valores de  $a_0$  e  $a_1$  que minimizam a soma dos quadrados dos resíduos:

$$S_r = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - a_0 - a_1 x_i)^2 \quad (\text{ii})$$

# Método dos mínimos quadrados

---

$$S_r = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - a_0 - a_1 x_i)^2$$

- Para determinar os parâmetros  $a_0$  e  $a_1$  deriva-se (ii) com relação a estes:

$$\frac{\partial S_r}{\partial a_0} = -2 \sum_{i=1}^n (y_i - a_0 - a_1 x_i)$$

$$\frac{\partial S_r}{\partial a_1} = -2 \sum_{i=1}^n (y_i - a_0 - a_1 x_i) x_i$$

# Método dos mínimos quadrados

---

- Para obter o mínimo, iguala-se as derivadas a zero:

$$\begin{aligned}\sum_{i=1}^n y_i - \sum_{i=1}^n a_0 - \sum_{i=1}^n a_1 x_i &= 0 \\ \sum_{i=1}^n y_i x_i - \sum_{i=1}^n a_0 x_i - \sum_{i=1}^n a_1 x_i^2 &= 0\end{aligned}$$

---

$$\frac{\partial S_r}{\partial a_0} = -2 \sum_{i=1}^n (y_i - a_0 - a_1 x_i)$$

$$\frac{\partial S_r}{\partial a_1} = -2 \sum_{i=1}^n (y_i - a_0 - a_1 x_i) x_i$$



# Método dos mínimos quadrados

---

- Prosseguindo e reorganizando:

$$na_0 + \left( \sum_{i=1}^n x_i \right) a_1 = \sum_{i=1}^n y_i \quad (\text{iii})$$

$$\left( \sum_{i=1}^n x_i \right) a_0 + \left( \sum_{i=1}^n x_i^2 \right) a_1 = \sum_{i=1}^n x_i y_i \quad (\text{iv})$$

- Resolvendo o sistema para  $a_1$  :

$$a_1 = \frac{n \sum_{i=1}^n x_i y_i - \sum_{i=1}^n x_i \sum_{i=1}^n y_i}{n \sum_{i=1}^n x_i^2 - \left( \sum_{i=1}^n x_i \right)^2} \quad (\text{v})$$

# Método dos mínimos quadrados

---

- Substituindo (v) em (iii), obtém-se  $a_0$  a partir de:

$$a_0 = \bar{y} - a_1 \bar{x} \quad (\text{vi})$$

onde  $\bar{x}$  e  $\bar{y}$  são as médias de  $x$  e  $y$

# EXEMPLO 1

Ajuste uma reta aos valores tabela ao lado.



$v \text{ (m/s)}$	$F \text{ (N)}$
10	25
20	70
30	380
40	550
50	610
60	1220
70	830
80	1450

## EXEMPLO 1

Nesse caso  $F = f(v)$ .  
Reorganizando os dados e totalizando os somatórios necessários, constrói-se a tabela ao lado.

$i$	$x_i$	$y_i$	$x_i^2$	$x_i y_i$	$y_i^2$
1	10	25	100	250	625
2	20	70	400	1400	4900
3	30	380	900	11400	144400
4	40	550	1600	22000	302500
5	50	610	2500	30500	372100
6	60	1220	3600	73200	1488400
7	70	830	4900	58100	688900
8	80	1450	6400	116000	2102500
$\Sigma$	360	5135	20400	312850	5104325

# EXEMPLO I

---

- A inclinação e a intersecção com o eixo y podem ser calculadas com as equações (v) e (vi):


$$a_1 = \frac{n \sum_{i=1}^n x_i y_i - \sum_{i=1}^n x_i \sum_{i=1}^n y_i}{n \sum_{i=1}^n x_i^2 - (\sum_{i=1}^n x_i)^2} = \frac{8 \cdot 312 - 360 \cdot 5135}{8 \cdot 20400 - 360^2} = \mathbf{19,47024}$$

$$a_0 = \bar{y} - a_1 \bar{x} = 641,875 - 19,47024 \cdot 45 = -\mathbf{234,2875}$$

- Utilizando F no lugar de y e v no lugar de x, o ajuste pelo MMQ é

$$\boxed{F = -234,29 + 19,47 v} \text{ (para } v \geq 12,03\text{)}$$

# EXEMPLO I — Ajuste de uma reta por mínimos quadrados



# Quantificação do erro - Regressão linear

- A soma dos quadrados dos resíduos é definida por

$$S_r = \sum_{i=1}^n (y_i - a_0 - a_1 x_i)^2$$

- Por analogia podemos determinar um “desvio padrão” para a reta de regressão:

$$S_{y/x} = \sqrt{\frac{S_r}{n-2}}$$

- Similar a soma dos quadrados dos resíduos entre os pontos dados e a média

$$S_t = \sum_{i=1}^n (y_i - \bar{y})^2$$

- Utilizada em estatística para calcular o desvio padrão:

$$S_y = \sqrt{\frac{S_t}{n-1}}$$

# Quantificação do erro - Regressão linear

---

- A diferença entre o módulo do erro residual antes da regressão

$$S_t = \sum_{i=1}^n (y_i - \bar{y})^2$$

e o erro que permanece depois da regressão

$$S_r = \sum_{i=1}^n (y_i - a_0 - a_1 x_i)^2$$

normalizada, é chamada de coeficiente de determinação

$$r^2 = \frac{S_t - S_r}{S_t}$$

- Para um ajuste perfeito,  $S_r = 0$  e  $r^2 = 1$ , ou seja a reta explica 100% da variação dos dados



# Método dos mínimos quadrados

---

- Uma equação alternativa para  $r^2$ , conveniente para cálculo computacional é:

$$r^2 = \left( \frac{n \sum_{i=1}^n x_i y_i - \sum_{i=1}^n x_i \sum_{i=1}^n y_i}{\sqrt{n \sum_{i=1}^n x_i^2 - (\sum_{i=1}^n x_i)^2} \sqrt{n \sum_{i=1}^n y_i^2 - (\sum_{i=1}^n y_i)^2}} \right)^2$$

- Utilizando a equação acima, calcula-se o coeficiente de determinação do ajuste realizado no Exemplo 1:

$$r^2 = \left( \frac{a_1 = \frac{n \sum_{i=1}^n x_i y_i - \sum_{i=1}^n x_i \sum_{i=1}^n y_i}{n \sum_{i=1}^n x_i^2 - (\sum_{i=1}^n x_i)^2}}{\sqrt{8 \cdot 20400 - 360^2} \sqrt{8 \cdot 5135^2 - (24325)^2}} \right)^2 = 0,8805$$

- O que indica que 88,05% da incerteza original foi explicada pelo ajuste linear.








# Linearização de relações não lineares

---

- Nem sempre a relação entre a variável dependente e a independente é linear.
- Nesses casos, podem ser usadas transformações para expressar os dados em uma forma que seja compatível com a regressão linear:
  - ✓ Equação exponencial:  $y = \alpha e^{\beta x}$
  - ✓ Equação de potência simples:  $y = \alpha x^{\beta}$
  - ✓ Equação da taxa de crescimento de saturação:  $y = \alpha \frac{x^m}{\beta + x^m}$

onde  $m$  é a ordem do ajuste

# Linearização de relações não lineares



# Linearização de relações não lineares

- Equação exponencial:

$$\text{➤ } y = \alpha e^{\beta x} \quad \rightarrow \quad \ln y = \ln \alpha + \beta x$$

- Equação de potência simples:

$$\text{➤ } y = \alpha x^{\beta} \quad \rightarrow \quad \log y = \log \alpha + \beta \log x$$

- Equação da taxa de crescimento de saturação:

$$\text{✓ } y = \alpha \frac{x^m}{\beta + x^m} \quad \rightarrow \quad \frac{1}{y} = \frac{1}{\alpha} + \frac{\beta}{\alpha} \frac{1}{x^m}$$

## EXEMPLO 2

Ajuste a equação  $y = \alpha x^\beta$  aos dados da tabela ao lado usando uma transformação de potência simples



v (m/s)	F (N)
10	25
20	70
30	380
40	550
50	610
60	1220
70	830
80	1450

## EXEMPLO 2

Nesse caso  $F = f(v)$ .  
Reorganizando os dados e totalizando os somatórios necessários, constrói-se a tabela ao lado.

$i$	$x_i$	$y_i$	$\log x_i$	$\log y_i$	$(\log x_i)^2$	$\log x_i \log y_i$	$(\log y_i)^2$
1	10	25	1,0000	1,3979	1,0000	1,3979	1,9542
2	20	70	1,3010	1,8451	1,6927	2,4005	3,4044
3	30	380	1,4771	2,5798	2,1819	3,8107	6,6553
4	40	550	1,6021	2,7404	2,5666	4,3902	7,5096
5	50	610	1,6990	2,7853	2,8865	4,7322	7,7581
6	60	1220	1,7782	3,0864	3,1618	5,4880	9,5256
7	70	830	1,8451	2,9191	3,4044	5,3860	8,5210
8	80	1450	1,9031	3,1614	3,6218	6,0164	9,9942
$\Sigma$	360	5135	12,606	20,515	20,516	33,622	55,322

## EXEMPLO 2

---

- A inclinação e a intersecção com o eixo y podem ser calculadas com as equações (iii) e (v):

$$a_1 = \frac{n \sum_{i=1}^n x_i y_i - \sum_{i=1}^n x_i \sum_{i=1}^n y_i}{n \sum_{i=1}^n x_i^2 - (\sum_{i=1}^n x_i)^2} = \frac{8 \cdot 33,622 - 12,606 \cdot 20,515}{8 \cdot 20,516 - 12,606^2} = \mathbf{1,9842}$$

$$a_0 = \bar{y} - a_1 \bar{x} = 2,5644 - 1,9842 \cdot 1,5757 = \mathbf{-0,5620}$$

- Utilizando F no lugar de y e v no lugar de x, o ajuste pelo MMQ é

$$\log F = -0,5620 + 1,9842 \log v$$

$$y = \alpha x^\beta \quad \rightarrow \quad \log y = \log \alpha + \beta \log x$$

## EXEMPLO 2

---

- Para exibir o ajuste usando coordenadas não transformadas:

$$a_0 = \log \alpha \quad \rightarrow \quad \alpha = 10^{a_0}$$

$$a_1 = \beta$$

- Substituindo os valores:

$$\alpha = 10^{-0,562} = 0,2741$$



$$a_1 = 1,9842$$

- O ajuste por mínimos quadrados é

$$F = 0,27 v^{1,98}$$

com coeficiente de determinação (calcule)  $r^2 = 0,9481$






## EXEMPLO 2 — Ajuste com equação de potência simples

A Figura ao lado representa o ajuste por mínimos quadrados de um modelo de potência simples aos dados sendo:

(a) o ajuste dos dados transformados e

(b) o ajuste da equação de potência juntamente com os dados

## EXEMPLO 3



A tabela ao lado contém os registros efetuados dos valores médios da radiação solar em uma localidade para alguns meses do ano.

Ajuste o modelo

$$M(x) = a_1 (x - 6)^4 + a_0 \operatorname{sen} \left( \frac{\pi}{12} x \right)$$

aos valores da tabela, no sentido dos mínimos quadrados, e use o modelo encontrado para prever a radiação média no mês de Agosto.

Um langley (Ly) é uma unidade de distribuição de energia por área Um langley é definido como uma caloria termoquímica por  $\text{cm}^2$ . Em unidades SI, 1 langley vale  $41,840 \text{ J/m}^2$ .

Mês	Radiação (Ly/dia)
1	122
3	188
6	270
10	160
12	120

# EXEMPLO 3

---

- Olhando para a prova do Método dos Mínimos Quadrados, percebe-se que não é essencial que  $y = a_1x + a_0$ ; poderia ser  $y = a_1f(x) + a_0g(x)$ . Nesse caso:

$$a_1 = \frac{\sum_{i=1}^n g(x_i)^2 \sum_{i=1}^n f(x_i)y_i - \sum_{i=1}^n f(x_i)g(x_i) \sum_{i=1}^n g(x_i)y_i}{\sum_{i=1}^n f(x_i)^2 \sum_{i=1}^n g(x_i)^2 - \left(\sum_{i=1}^n f(x_i)g(x_i)\right)^2}$$

$$a_0 = \frac{\sum_{i=1}^n g(x_i)y_i - a_1 \sum_{i=1}^n f(x_i)g(x_i)}{\sum_{i=1}^n g(x_i)^2}$$

$$r^2 = \left( \frac{\sum_{i=1}^n g(x_i)^2 \sum_{i=1}^n f(x_i)y_i - \sum_{i=1}^n f(x_i)g(x_i) \sum_{i=1}^n g(x_i)y_i}{\sqrt{\sum_{i=1}^n f(x_i)^2 \sum_{i=1}^n g(x_i)^2 - \left(\sum_{i=1}^n f(x_i)g(x_i)\right)^2} \sqrt{\sum_{i=1}^n g(x_i)^2 \sum_{i=1}^n y_i^2 - \left(\sum_{i=1}^n g(x_i)y_i\right)^2}} \right)^2$$

## EXEMPLO 3

Trata-se de um modelo linear não polinomial, com

$$f(x) = (x - 6)^4 \quad \text{e} \quad g(x) = \text{sen}\left(\frac{\pi}{12}x\right)$$

Reorganizando os dados e totalizando os somatórios necessários, constrói-se a tabela abaixo.

$x_i$	$y_i$	$f(x_i)$	$g(x_i)$	$f(x_i)^2$	$g(x_i)^2$	$f(x_i)g(x_i)$	$f(x_i) y_i$	$g(x_i) y_i$	$y_i^2$
1	122	625	0,25882	390625	0,0670	161,7623	76250	31,5760	14884
3	188	81	0,70711	6561	0,5000	57,2758	15228	132,9363	35344
6	270	0	1	0	1	0	0	270	72900
10	160	256	0,49999	65536	0,2500	127,9986	40960	79,9992	25600
12	120	1296	-0,00001	1679616	0,0000	-0,0095	155520	-0,0009	14400
$\Sigma$		2258	2,4659	2142338	1,8170	347,0271	287958	514,5106	163128

# EXEMPLO 3

---

- Calculando a inclinação e a intersecção com o eixo y, resulta :

$$a_1 = 0,0914$$

$$a_0 = 265,7164$$

- E o modelo obtido é

$$M(x) = 0,0914 (x - 6)^4 + 265,7 \operatorname{sen}\left(\frac{\pi}{12}x\right)$$


com coeficiente de determinação  $r^2 = 0,9941$ .

- Com  $x = 8$ , obtém-se a radiação média no mês de agosto:

$$M(x) = 0,0914 (2)^4 + 265,7 \operatorname{sen}\left(\frac{2\pi}{3}\right) = 231,7 \text{ Ly/dia}$$

## EXEMPLO 3 – Modelo MMQ generalizado

A Figura ao lado  
representa o ajuste  
por mínimos  
quadrados com o  
modelo generalizado  
juntamente com os  
dados



1) A concentração de bactéria E. Coli em uma área de prática de natação é monitorada após uma tempestade:

$t \text{ (h)}$	4	8	12	16	20	24
$c(\text{UFC}/100 \text{ ml})$	1600	1320	1000	890	650	560

O tempo é medido em horas seguindo o fim da tempestade, e a unidade UFC é uma Unidade Formadora de Colônia. Use esses dados para estimar (a) a concentração no fim da tempestade  $t = 0$  e (b) o instante de tempo em que a concentração alcança 200 *UFC/100 ml*.




## Exercícios

2) Um pesquisador relatou os dados tabulados a seguir para uma experiência a fim de determinar a taxa de crescimento da bactéria  $k$  (por dia) como uma função da concentração de oxigênio  $c$  ( $mg/l$ ). Sabe-se que tais dados podem ser modelados pela seguinte equação:

$$y = k_m \frac{c^2}{c_s + c^2}$$

onde  $c_s$  e  $k_m$  são parâmetros Use uma transformação para linearizar esta equação. A seguir use a regressão linear para estimar  $c_s$  e  $k_m$  e prever a taxa de crescimento em  $c = 2 \text{ mg/l}$ .

$c$	0,5	0,8	1,5	2,5	4
$k$	1,1	2,5	5,3	7,6	8,9



## Exercícios





---

# Função Scilab

---

## Função Scilab

```
function [alfa, betha, r]=reglinear(x, y, e, m)
/* x vetor com os pontos da variável independente
y vetor com os pontos da variável dependente
e: 'r' - reta, 'e' - exp, 'p' - potencia, 's' - saturação
se for s tem que passar a potencia m */
a=[0 0];
n = length(x)
if n~=length(y) then
    error("inconsistencia nos dados");
end
plot(x,y,'o')
xx = linspace(min(x),max(x),100);
```

# Função Scilab

```
if (e == 'e') then
    y = log(y);
elseif (e == 'p') then
    x = log10(x);
    y = log10(y);
elseif (e == 's') then
    x = 1 ./ x.^m;
    y = 1 ./ y;
elseif (e == 'r')
    // não necessita ajuste nos eixos
else
    error("opção inexistente");
end
```

# Função Scilab

```
somax=sum(x); somay=sum(y); somaxy=sum(x.*y);
```

```
somaxx=sum(x.^2); somayy=sum(y.^2);
```

```
A = n*somaxy - somax*somay;
```

```
B = n*somaxx - somax^2;
```

```
C = n*somayy - somay^2;
```

```
a(2) = A/B; // a1
```

```
a(1) = somay/n - a(2)*somax/n; // a0
```

```
r = (A/(sqrt(B)*sqrt(C)))^2;
```

# Função Scilab

```
if (e == 'e') then
    betha = a(2);
    alfa = exp(a(1));
    yy = alfa * exp(betha * xx);
elseif (e == 'p') then
    betha = a(2);
    alfa = 10^(a(1))
    yy = alfa * xx.^betha
elseif (e == 's') then
    alfa = 1/a(1);
    betha = alfa * a(2);
    yy = alfa * xx.^m ./ (betha + xx.^m);
```

# Função Scilab

```
elseif (e == 'r')  
    yy = a(1)+a(2)*xx;  
    alfa = a(1);  
    betha = a(2);  
  
end  
  
plot(xx,yy)  
xgrid;  
  
endfunction
```

*Teste a sua função conferindo com os resultados obtidos nos Exemplos 1 e 2 e nos Exercícios 1 e 2.*

# Bibliografia e crédito das figuras

---



CHAPRA, Steven. **Applied numerical methods with MATLAB for engineers and scientists.** McGrawHill, 2012.



CHAPRA, Steven e CANALE, Raymond. **Numerical methods for engineers.** McGrawHill, 2010.